
Multimodal Emotion Recognition in DUUI

Kick-off Praktikum

Max Froese · Christian Block · Nickolas Eickmann

May 29, 2026

Themenshift: Video → Multimodal

- Klassische ViT-Modelle → starker Kontext-Bias
(~75 % „sad“ auf Bundestags-Material: Kopfhaltung, frontale Einstellung)
- ⇒ Verschiebung des Fokus auf **multimodale** Emotionserkennung

Video → Audio → Text

Reader → WhisperX → spaCy → SentenceAligner

- **WhisperX**: Audio → Text mit Word-Timestamps
- **spaCy**: Satzgrenzen
- ⇒ **text-anchored Segmente**:
SentenceSegment = Text-Offsets + Zeitintervalle

3 Modalitäten → ein TypeSystem

- Face/V/A + FACS · Audio-Prosodie · Text-Emotion
- Heterogene Outputs (kategorial / V/A / Action Units) ↔ gemeinsames TypeSystem
- Erstmal **ein fester Segment-Anker**
- Konkrete Modelle: noch offen

Phase 1: Sentence-anchored Pipeline

- Diese Pipeline end-to-end bauen
- Ziel: lauffähig auf kleinem Bundestag-Sample
- TypeSystem wächst mit den Komponenten mit

Nach Phase 1: drei Richtungen

- **Aufräumen**

Reader / Writer / SentenceAligner zunächst Java-„Glue“ (JCas außerhalb der Pipeline) → in volle DUUI-Container überführen

- **Generalisieren** → Folie 7

- **Evaluiieren** → Folie 8

- Frage: Pipeline ohne Text-Anker?
- Nur Video + Audio → künstliche Segmente (`VideoSegmenter`)
- Generischer Segment-Supertyp, Komponenten in beiden Regimen nutzbar

Aggregation auf drei Zeitebenen:

- **Micro** – pro Segment
- **Meso** – pro Sprecher: Dauer, Volatilität
- **Macro** – ganze Sitzung: Shifts, Eskalation

Optional: VLM-Vergleich

- Phi-4 / Qwen-VL mit Frame + Audio + Text
- Output vergleichbar gemacht (V/A, Ekman) $\leftrightarrow$ klassische Pipeline
- Stretch goal, nicht kritischer Pfad

Worum es eigentlich geht

Beitrag = Pipeline-Konstruktion, nicht Modellqualität

- **Time-Axis-Handling** – text- vs. frame-/zeit-basiert
- **Video-Spezifika** – Framerates, Auflösung, Codecs, Metadaten
- **TypeSystem-Design** – Schema mit gemeinsamen Ankern

Zeitplan

